

Corso di High Performance Computing

Esercitazione MPI del xx/4/2017

Moreno Marzolla

Ultimo aggiornamento: 2017/04/27

Per svolgere l'esercitazione è possibile collegarsi al server `disi-hpc.csr.unibo.it` tramite ssh, usando come *username* il proprio indirizzo mail istituzionale completo, e come password la propria password istituzionale (cioè quella usare per accedere alla casella di posta o ad AlmaEsami). Sulla macchina è installato il compilatore gcc e alcuni editor di testo per console: vim, pico, joe, ne e emacs. Per chi non è pratico suggerisco pico, che è semplice da usare e richiede poche risorse. Chi ha un portatile con Linux può lavorare localmente, dopo aver installato il compilatore.

Per scaricare l'archivio con i sorgenti di questa esercitazione è possibile usare i comandi:

```
wget http://www.moreno.marzolla.name/teaching/HPC/ex3-mpi.zip
unzip ex3-mpi.zip
cd ex3-mpi/
```

Alcuni degli esercizi producono immagini in formato PBM (*Portable Bitmap*) che le macchine Windows dei laboratori non sono in grado di visualizzare. È necessario convertire tali immagini in un formato diverso (ad esempio, PNG) dando sul server un comando come:

```
convert image.pbm image.png
```

per poi copiare il file risultante sul proprio PC usando il programma Winscp (già installato).

1. Automa cellulare della "regola 30"

Quando abbiamo parlato dei pattern per la programmazione parallela abbiamo introdotto gli automi cellulari (CA) come semplice esempio di computazioni di tipo *stencil*. In questo esercizio consideriamo l'automa cellulare prodotto dalla "regola 30". L'automa è costituito da un array $a[N]$ di N interi, ciascuno dei quali può avere valore 0 oppure 1. Lo stato dell'automa evolve durante istanti discreti nel tempo: lo stato di una cella al tempo t dipende dal suo stato e da quello dei due vicini al tempo $t - 1$. Assumiamo un dominio ciclico, per cui ad esempio i vicini della cella $a[0]$ sono $a[N - 1]$ e $a[1]$.


Nella "regola 30", dati gli stati correnti pqr di tre celle adiacenti, il nuovo stato q' della cella centrale è determinato dalla tabella seguente:

Configurazione corrente (pqr)	111	110	101	100	011	010	001	000
Nuovo stato della cella centrale (q')	0	0	0	1	1	1	1	0

(si noti che la sequenza 00011110 rappresenta il numero 30 in binario, da cui il nome "regola 30").

Il file `mpi-rule30.c` contiene lo scheletro di una implementazione seriale dell'algoritmo che calcola l'evoluzione dell'automa. Inizialmente tutte le celle sono nello stato 0, ad eccezione di quella in posizione $N/2$ che è nello stato 1. Il programma accetta sulla riga di comando la dimensione del dominio N e il numero di passi da calcolare (se non indicati, si usano dei valori di default). Al termine dell'esecuzione il processo 0 produce un file `rule30.pbm` che conterrà una immagine


simile alla seguente:



Ogni riga dell'immagine rappresenta lo stato dell'automa in un istante di tempo; il colore di ogni pixel indica lo stato di ciascuna cella (nero = 1, bianco = 0). Il tempo scorre dall'alto verso il basso, quindi la prima riga indica lo stato al tempo 0, la seconda riga lo stato al tempo 1 e così via.

Lo scopo di questo esercizio è di sviluppare una versione realmente parallela del programma, in cui il calcolo di ogni riga dell'immagine venga realizzato in parallelo da tutti i processi MPI.

Il programma deve operare secondo i passi seguenti (si faccia riferimento alla figura):



1. Il dominio viene distribuito ai P processi MPI usando `MPI_Scatter()`; si assuma che N sia

multiplo di P . Ciascuna partizione deve includere due *ghost cells* (una a sinistra e una a destra, mostrate tratteggiate in figura) che sono necessarie per calcolare lo stato successivo, come discusso a lezione.

2. Ogni processo comunica ai vicini i valori delle celle sul proprio bordo usando `MPI_Sendrecv`. Questa fase serve per riempire le *ghost cell* delle partizioni locali.
3. Ciascun processo calcola la configurazione successiva della propria porzione di dominio, sfruttando i valori delle *ghost cells*. Si può fare riferimento alla funzione `step()` inclusa nello scheletro di programma.
4. Ciascun processo invia la propria porzione di dominio, contenente la nuova configurazione, al master che le assembla usando `MPI_Gather` per poi salvarla sul file di output.

Al termine del passo 4 si riparte dal passo 2; dato che il nuovo stato dell'automa è già presente nella memoria di ciascun processo, non serve rifare `MPI_Scatter` ogni volta. Per i dettagli si rimanda ai lucidi in cui abbiamo discusso i pattern per la programmazione parallela. Il file `mpi-rule30.c` va usato come indicazione di massima su come procedere; sarà necessario modificarne pesantemente la struttura per poter realizzare lo schema parallelo descritto sopra.


I punti critici di questo esercizio sono: (i) l'uso di `MPI_Scatter()` e `MPI_Gather()` per distribuire e recuperare i sottodomini, e (ii) l'uso di `MPI_Sendrecv()` per consentire ai processi lo scambio delle ghost cells.

Per quanto riguarda il punto (i), ciascun sottodominio dovrà essere composto da $(N/\text{comm_sz} + 2)$ elementi (i due elementi aggiuntivi rappresentano le ghost cells). Se `x[]` denota il dominio completo con N elementi (usato dal master) e `local_x[]`, `local_next[]` rappresentano i sottodomini (ciascuno con $N/\text{comm_sz} + 2$ elementi), allora la distribuzione di `x[]` dovrà avere la forma:

```
MPI_Scatter( x,                /* sendbuf      */
             N/comm_sz,        /* sendcount    */
             MPI_INT,          /* datatype     */
             &local_x[1],      /* recvbuf      */
             N/comm_sz,        /* recvcount    */
             MPI_INT,          /* datatype     */
             0,                /* root         */
             MPI_COMM_WORLD
           );
```

L'istruzione precedente distribuisce $N/\text{comm_sz}$ elementi di `x[]`, in modo ciclico, tra i processi MPI; ciascuno di essi riceve il blocco a partire dall'indirizzo di memoria `&local_x[1]`, lasciando quindi indefinito il valore della ghost cell di sinistra e di destra.

Per quanto riguarda il punto (ii), conviene usare la funzione `MPI_Sendrecv()` per realizzare lo scambio di ghost cells tra processi adiacenti. Lo scambio richiede due fasi (si veda la figura sotto): nella prima fase ogni processo invia il valore dell'ultima cella al processo successivo, e riceve il valore della ghost cell di sinistra dal processo precedente; nella seconda fase ogni processo invia il contenuto della prima cella al processo precedente, e riceve il valore della ghost cell di destra dal processo successivo.



2. MPI Datatype

Quando si deve decomporre un dominio rettangolare di dimensione $R \times C$ tra un insieme di processi MPI si è soliti adottare una decomposizione a blocchi per righe (Block, *): il primo processo elabora le prime R/P righe; il secondo le successive R/P righe, e così via. Infatti, nel linguaggio C le matrici sono memorizzate per righe, e una decomposizione di tipo (Block, *) consente di avere le partizioni adiacenti in memoria semplificando l'invio dei dati tramite le funzioni MPI apposite. In questo esercizio consideriamo una decomposizione sulle colonne allo scopo di prendere familiarità con gli MPI_Datatype.

Scopo dell'esercizio è la realizzazione di un programma MPI in cui i processi 0 e 1 mantengono ciascuno una matrice di interi di dimensioni $SIZE \times SIZE$; le matrici includono una colonna a sinistra e a destra di *ghost cells* (dette anche *halo*), quindi la loro dimensione effettiva è $SIZE \times (SIZE + 2)$. Nello scheletro di programma `mpi-send-col.c` si pone $SIZE = 4$, ma il programma deve funzionare con qualunque valore.

I processi inizializzano le proprie matrici come segue (caso $SIZE = 4$)

	0	1	2	3			16	17	18	19	
	4	5	6	7			20	21	22	23	
	8	9	10	11			24	25	26	27	
	12	13	14	15			28	29	30	31	


Processo 0
Processo 1

Il processo 0 deve inviare l'ultima colonna della propria matrice al processo 1, che la inserisce nell'*halo* di sinistra; analogamente, il processo 1 deve inviare la prima colonna della propria matrice al processo 0, che la inserisce nell'*halo* di destra.

	0	1	2	3	16		3	16	17	18	19	
	4	5	6	7	20		7	20	21	22	23	
	8	9	10	11	24		11	24	25	26	27	
	12	13	14	15	28		15	28	29	30	31	

Processo 0
Processo 1

Per completare lo scambio delle colonne sul bordo il processo 0 invia ora la prima colonna della propria matrice al processo 1, che la inserisce nell'*halo* di destra; il processo 1 invia l'ultima colonna (quella di destra) della propria matrice al processo 0, che la inserisce nell'*halo* di destra.




3. Calcolo dell'area dell'unione di N cerchi

Il file `mpi-circles.c` contiene una implementazione seriale di un algoritmo randomizzato di tipo Monte Carlo per stimare l'area dell'unione N cerchi. Siano $cx[i]$, $cy[i]$ le coordinate del centro del cerchio i -esimo, e $r[i]$ il suo raggio; tutti i cerchi sono interamente contenuti all'interno del quadrato avente gli angoli opposti di coordinate $(0, 0)$, $(1000, 1000)$. Poiché i cerchi possono essere collocati in posizioni arbitrarie, potrebbero sovrapporsi in tutto o in parte; di conseguenza non è semplice determinare l'area della loro unione. Un metodo per stimare l'area consiste nell'utilizzare il metodo seguente:

- Si generano K punti distribuiti uniformemente all'interno del quadrato di coordinate $(0, 0)$, $(1000, 1000)$. Sia C il numero di tali punti che si trovano all'interno di almeno un cerchio.
- L'area A dell'unione dei cerchi è data dal prodotto tra l'area del quadrato che li contiene (nel nostro caso 1000×1000) e la frazione di punti che ricadono all'interno di almeno un cerchio, ossia $A = 1'000'000 \times C / S$;

La figura seguente illustra il concetto. L'area dell'unione dei cerchi viene approssimata come il prodotto tra l'area del quadrato contenente i cerchi e il rapporto tra il numero di punti che si trovano all'interno di almeno un cerchio e il numero totale di punti casuali generati.



Viene fornito il file `mpi-circles.c` contenente uno schema di soluzione seriale, in cui il processo 0 esegue tutte le operazioni. Scopo di questo esercizio è di distribuire la computazione tra tutti i processi MPI. E' richiesto che solo il processo 0 legga il file di input. Questo significa che solo il processo 0 conosce il numero N di cerchi e le loro coordinate; se tali informazioni sono necessarie agli altri processi, il master le deve comunicare esplicitamente. Il programma deve funzionare correttamente per qualsiasi valore di N e K .

Suggerimento: si potrebbe essere tentati di partizionare i cerchi tra i processi MPI, in modo che ciascun processo gestisca N/P cerchi. Questa però **non** sarebbe una buona idea, perché...